

Reporte final — Evaluación del modelo de riesgo crediticio

Rol 4: Documentation Lead — PB-18

Entregable: `reports/final_report.pdf`

Este notebook consolida el reporte ejecutivo solicitado para Sprint 5.

Incluye contexto, datos, modelo final, valor de negocio, riesgos, recomendaciones, anexos técnicos y generación de visualizaciones clave.

Importante: el Sprint 5 no reentrena modelos. Carga el artefacto final de Sprint 4 (`models/final_model.pkl`) y evalúa valor de negocio sobre el holdout definido con `test_size=0.2`, `stratify=y` y `random_state=42`.

1. Resumen ejecutivo

El proyecto aborda la **gestión de riesgo crediticio** mediante un modelo de clasificación para anticipar qué clientes de tarjeta de crédito podrían caer en mora el próximo mes.

El dataset utilizado contiene **30,000 clientes** con información demográfica, límite de crédito, historial de pagos, montos facturados y montos pagados. La variable objetivo es `default payment next month`, donde `1` representa mora y `0` no mora.

El criterio mínimo de éxito definido en Sprint 1 fue lograr un **ROC-AUC ≥ 0.70** , complementado con recall y F1-score, dado que el problema de negocio prioriza detectar clientes con riesgo de incumplimiento.

Durante Sprint 2 se prepararon los datos mediante limpieza, tratamiento de outliers, encoding, escalado y creación de variables financieras como utilización de crédito, ratio de pago, pagos tardíos, tendencia de deuda y capacidad de pago.

En Sprint 4 se seleccionaron y optimizaron modelos con balanceo mediante `RandomOverSampler`. El modelo final se usa en Sprint 5 sin reentrenamiento para estimar su valor de negocio, definir un umbral óptimo y generar recomendaciones para stakeholders.

Desde una perspectiva de negocio, el modelo permite priorizar acciones preventivas sobre clientes con mayor probabilidad de mora. El análisis de Sprint 5 recomienda evaluar el despliegue del MVP con un **umbral económico optimizado**, no necesariamente el umbral estándar de 0.5, porque la decisión debe maximizar valor esperado y no solo métricas técnicas.

2. Contexto del negocio — Sprint 1

El sector bancario y fintech enfrenta un problema recurrente: la morosidad en tarjetas de crédito. Los incumplimientos generan pérdidas financieras, deterioran la cartera y afectan la estabilidad del

negocio.

El objetivo del proyecto es identificar anticipadamente clientes con alta probabilidad de incumplir el pago mensual para habilitar acciones preventivas como:

- priorización de cobranza,
- oferta de planes de pago,
- ajuste de límites de crédito,
- monitoreo preventivo de cartera.

Variable objetivo:

`default payment next month`

- `0` : cliente no cae en mora.
- `1` : cliente cae en mora el próximo mes.

Criterios de éxito definidos:

- Métrica principal: ROC-AUC.
- Umbral mínimo aceptable: $\text{ROC-AUC} \geq 0.70$.
- Métricas complementarias: recall y F1-score.

3. Datos y preparación — Sprint 2

El dataset original contiene:

- 30,000 registros.
- 25 variables iniciales.
- Sin valores nulos.
- Sin duplicados.
- Target desbalanceado: aproximadamente 77.88% clase 0 y 22.12% clase 1.

Principales decisiones de preparación:

1. Se mantuvo `ID` solo como identificador, excluyéndolo del entrenamiento.
2. Se trataron `SEX`, `EDUCATION` y `MARRIAGE` como categóricas.
3. Se aplicó tratamiento de outliers mediante IQR.
4. Se aplicó One-Hot Encoding.
5. Se escalaron variables numéricas.
6. Se generaron nuevas variables financieras:
 - `avg_bill`
 - `credit_utilization`
 - `avg_pay`
 - `payment_ratio`
 - `late_payments`
 - `bill_trend`
 - `pay_trend`
 - `risk_score`

- `ability_to_pay`
- `log_limit`
- `log_avg_bill`

7. Se evaluaron técnicas de balanceo. `RandomOverSampler` y `RandomUnderSampler` destacaron por mayor recall de la clase 1.

Dimensiones: (30000, 45)

	ID	LIMIT_BAL	AGE	PAY_0	PAY_2	PAY_3	PAY_4	PAY_5	PAY_6	BILL_AMT1	...	payment_ratio
0	1	20000	24.0	1.5	1.5	-1.0	-1.0	-2.0	-2.0	3913.0	...	0.089364
1	2	120000	26.0	-1.0	1.5	0.0	0.0	0.0	1.5	2682.0	...	0.292689
2	3	90000	34.0	0.0	0.0	0.0	0.0	0.0	0.0	29239.0	...	0.108382
3	4	50000	37.0	0.0	0.0	0.0	0.0	0.0	0.0	46990.0	...	0.036258
4	5	50000	57.0	-1.0	0.0	-1.0	0.0	0.0	0.0	8617.0	...	0.307453

5 rows × 45 columns



Distribución del target:
 default payment next month
 0 23364
 1 6636
 Name: count, dtype: int64
 default payment next month
 0 0.7788
 1 0.2212
 Name: proporcion, dtype: float64

Train: (24000, 43) Test: (6000, 43)
 Tasa de mora train: 0.2212
 Tasa de mora test: 0.2212

4. Modelo final — Sprint 4

En Sprint 4 se realizó la optimización de hiperparámetros sobre los mejores candidatos del Sprint 3.

Top 3 modelos evaluados antes del tuning:

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
SVM_Over	0.7739	0.4910	0.5975	0.5390	0.7653
GradientBoosting_Over	0.7627	0.4725	0.6228	0.5373	0.7803
AdaBoost_Over	0.7663	0.4775	0.5957	0.5300	0.7708

Resultados del tuning reportados:

Modelo	Mejor configuración reportada	F1 después
SVM_Over	<code>C≈0.5154 , kernel='rbf' , gamma='scale'</code>	0.5427
GradientBoosting_Over	<code>n_estimators=69 , learning_rate≈0.0879 , max_depth=3</code>	0.5378
AdaBoost_Over	<code>n_estimators=81 , learning_rate≈0.0993</code>	0.5219

El modelo final se carga desde `models/final_model.pkl` y se evalúa sobre el holdout sin hacer `.fit()` en este notebook.

Modelo cargado correctamente.
`<class 'imblearn.pipeline.Pipeline'>`

	accuracy	precision	recall	f1	roc_auc
Umbral 0.50	0.7797	0.5016	0.584	0.5397	0.7729
	precision	recall	f1-score	support	
0	0.88	0.84	0.86	4673	
1	0.50	0.58	0.54	1327	
accuracy			0.78	6000	
macro avg	0.69	0.71	0.70	6000	
weighted avg	0.79	0.78	0.79	6000	

4.3 Métricas con intervalo de confianza

Se calcula un intervalo de confianza mediante bootstrap sobre el holdout. Esto permite reportar incertidumbre de las métricas finales sin reentrenar el modelo.

	Métrica	Media bootstrap	IC 95% inferior	IC 95% superior
0	ROC-AUC	0.7733	0.7586	0.7889
1	Recall	0.5851	0.5585	0.6155
2	F1-score	0.5405	0.5178	0.5639

5. Valor de negocio — Sprint 5

Sprint 5 traduce el desempeño técnico a impacto económico. Para ello se utiliza una matriz costo-beneficio con las siguientes convenciones:

- **TP:** el modelo identifica correctamente a un cliente moroso. Se activa intervención preventiva.
- **FP:** el modelo marca como riesgoso a un cliente que no caería en mora. Implica costo operativo o falsa alarma.
- **FN:** el modelo no identifica a un cliente que sí cae en mora. Representa pérdida no mitigada.
- **TN:** cliente correctamente clasificado como no riesgoso. Se considera neutro en esta matriz.

Supuestos económicos reportados en Sprint 5:

- Beneficio TP: **USD 600**
- Costo FP: **USD 30**
- Costo FN: **USD 740**
- Volumen anual referencial: **600,000 cuentas**

Fórmula:

[$EV = 600 \cdot TP - 30 \cdot FP - 740 \cdot FN$]

	Escenario	Umbral	TN	FP	FN	TP	Valor neto test USD	Valor anual estimado USD
0	Umbral óptimo EV	0.22708	78	4595	1	1326	657010.0	65701000.0
1	Umbral 0.50	0.50000	3903	770	552	775	33420.0	3342000.0

Umbral óptimo económico: 0.2271

Valor neto en test con umbral óptimo: \$657,010 USD

Valor anual estimado con umbral óptimo: \$65,701,000 USD

Valor neto en test con umbral 0.50: \$33,420 USD

5.3 Visualizaciones clave

Las siguientes celdas **generan y muestran imágenes directamente en el notebook**.

Además, cada gráfico se guarda en `reports/figures/` para que el PDF pueda incluirlas.




Imagen guardada en: ..\reports\figures\confusion_matrix_umbral_optimo.png




Imagen guardada en: `..\reports\figures\roc_curve.png`

Top 20% población ordenada por score:

Morosos capturados: 0.503

Lift vs azar: 2.513x




Imagen guardada en: ..\reports\figures\gain_chart.png




Imagen guardada en: ..\reports\figures\lift_chart.png





Imagen guardada en: ..\reports\figures\expected_value_by_threshold.png

BASE_DIR: C:\Users\DIANA\Desktop\dp261-g3

REPORTS_DIR: C:\Users\DIANA\Desktop\dp261-g3\reports

FIGURES_DIR: C:\Users\DIANA\Desktop\dp261-g3\reports\figures

0% | 0/50 [00:00<?, ?it/s]



6. Riesgos y limitaciones

6.1 Sesgos en los datos

Hallazgo: El dataset tiene desbalance de clases: la mora representa alrededor de 22.12% de los casos.

Evidencia: Distribución del target en Sprint 1 y Sprint 2.

Impacto: El modelo puede priorizar correctamente la clase mayoritaria y subdetectar clientes morosos si se usa un umbral estándar.

Recomendación: Evaluar el modelo por recall/F1 de la clase 1 y usar umbral económico.

Próximos pasos: QA debe validar métricas por subgrupos como edad, sexo, educación y nivel de crédito.

6.2 Deriva o drift

Hallazgo: El modelo fue entrenado con datos históricos de abril a septiembre de 2005.

Evidencia: Contexto del dataset.

Impacto: Cambios en comportamiento de pago, economía o políticas de crédito pueden degradar el desempeño.

Recomendación: Monitorear distribución de variables clave como `PAY_0`, `LIMIT_BAL`, `credit_utilization`, `payment_ratio` y tasa de mora.

Próximos pasos: Sprint 6 debe incluir monitoreo mensual de drift y gatillo de reentrenamiento.

6.3 Supuestos críticos

Hallazgo: Varias variables usadas por el modelo dependen de información histórica de pagos y facturación.

Evidencia: Features `PAY_*`, `BILL_AMT*`, `PAY_AMT*` y variables derivadas.

Impacto: Si estas variables no están disponibles en producción, la predicción puede fallar o perder calidad.

Recomendación: Definir contrato de datos mínimo para despliegue.

Próximos pasos: Crear `input_schema.json` y pruebas de validación previas a inferencia.

6.4 Costos del modelo

Hallazgo: Modelos con pipelines, oversampling y explicabilidad pueden requerir mantenimiento adicional.

Evidencia: Uso de `final_model.pkl`, pipeline y SHAP.

Impacto: Puede afectar tiempos de inferencia, reproducibilidad y soporte operativo.

Recomendación: Medir latencia y memoria antes del despliegue.

Próximos pasos: Sprint 6 debe definir SLA de inferencia y monitoreo.

6.5 Cumplimiento y regulación

Hallazgo: El caso corresponde a riesgo crediticio, un dominio sensible y regulado.

Evidencia: Uso de variables demográficas y decisión potencial sobre clientes.

Impacto: Riesgo de decisiones no explicables o discriminatorias.

Recomendación: Usar el modelo como apoyo a la decisión, no como decisión automática final.

Próximos pasos: Validar explicabilidad, trazabilidad y revisión humana.

6.6 Limitación de generalización

Hallazgo: El modelo fue entrenado sobre un periodo y país específico.

Evidencia: Dataset de clientes de tarjeta de crédito en Taiwán.

Impacto: No se puede asumir desempeño equivalente en otra cartera o país sin validación.

Recomendación: Validar con datos actuales del negocio antes de producción.

Próximos pasos: Ejecutar piloto controlado con datos recientes.

7. Recomendaciones

7.1 Decisión de despliegue

Se recomienda **desplegar un MVP controlado**, no un despliegue total inmediato.

La recomendación se sustenta en:

- el modelo supera el criterio técnico mínimo esperado de $ROC-AUC \geq 0.70$ si el resultado de ejecución se mantiene sobre ese valor,
- el análisis económico muestra que el umbral óptimo puede generar mayor valor esperado que el umbral estándar de 0.5,
- el gain chart permite priorizar clientes con mayor probabilidad de mora,
- el modelo requiere monitoreo por tratarse de riesgo crediticio.

7.2 Umbral recomendado

Usar el **umbral óptimo económico calculado en Sprint 5**:

best_t

Este umbral debe ser validado con negocio porque depende de supuestos económicos:

- beneficio por intervenir correctamente a un cliente moroso,
- costo de falsa alarma,
- costo de no intervenir ante un cliente moroso real.

7.3 Segmentos sugeridos para el MVP

Priorizar:

1. Clientes con alto score de probabilidad de mora.
2. Clientes ubicados en el top 20% del ranking de riesgo.
3. Clientes con historial reciente de pagos tardíos (`PAY_0` , `PAY_2` , `late_payments`).
4. Clientes con alta utilización de crédito (`credit_utilization`).
5. Clientes con bajo ratio de pago (`payment_ratio`).

7.4 Próximos pasos

Acción	Responsable sugerido	Plazo
Validar supuestos económicos con sponsor	Business Analyst	Antes del Sprint Review
Revisar métricas por subgrupo	QA Reviewer	Sprint 5
Validar contrato de datos de producción	QA + Deployment Lead	Inicio Sprint 6
Desplegar API MVP	Equipo Sprint 6	Sprint 6
Monitorear drift y performance	Equipo Data	Mensual